

Rapport de conception — Entrepôt de Données de Santé

Module Big Data M2 · Épreuve E05

Besoin, sources, architecture justifiée, traitements, indicateurs, visualisations, limites et recommandations — pour les deux livraisons.

L'automatisation, la journalisation, la traçabilité et la conduite au quotidien font l'objet d'un document séparé : [Guide d'exploitation](#).

Sommaire

Rapport de conception — Entrepôt de Données de Santé

Première livraison — Le socle

1. Le besoin métier
 - 1.1 Les sources fournies
 2. Les choix et leur justification
 - 2.1 Une exploration avant toute décision
 - 2.2 La pseudonymisation, au plus tôt possible
 - 2.3 Un cloisonnement physique, pas conventionnel
 - 2.4 Le risque de ré-identification, mesuré puis corrigé
 - 2.5 Un modèle en étoile, et un catalogue de KPI
 - 2.6 Le traitement s'exécute dans le moteur
 - 2.7 Incrémental en amont, recalcul en aval
 - 2.8 Rien n'est perdu silencieusement
 - 2.9 Ce qui change à chaque passage de couche
 - 2.10 Les six indicateurs, et ce qui les rend opposables
 - 2.11 La restitution, et pourquoi elle n'affaiblit pas le cloisonnement
 3. Architecture, limites et recommandations
 - 3.1 Schéma
 - 3.2 Traçabilité
 - 3.3 Limites
 - 3.4 Recommandations
-

Seconde livraison — L'évolution du besoin

4. Actes, description de service et facturation
 - 4.1 Ce que le CHU demande, et ce qui change
 - 4.2 Un référentiel n'est pas un jour de dépôt
 - 4.3 « Sans retraiter l'existant » — la propriété était déjà là
 - 4.4 Le premier piège : un référentiel incomplet
 - 4.5 Le second piège : le service vient du séjour
 - 4.6 Ce que l'étoile devient
 - 4.7 Les cinq indicateurs
 - 4.8 La qualité des actes, démontrée sur des règles qui ne servent pas
 - 4.9 Deux défauts trouvés en chemin

4.10 Ce qu'il a fallu accepter

4.11 Ce que cette évolution apprend

Première livraison — Le socle

Livraison initiale. Construction du pipeline `bronze → silver → gold`, cloisonnement pilotage / recherche, indicateurs du § 4 du sujet et restitution Metabase.

1. Le besoin métier

Le CHU dispose de données éparpillées entre quatre systèmes — dossier patient, urgences, laboratoire, monitoring des chambres — exportées chaque jour dans des formats hétérogènes (CSV, JSON imbriqué, Parquet). Personne ne peut aujourd'hui répondre à une question transverse sans consolider ces exports à la main.

Deux publics, aux besoins opposés :

	Attend	Granularité requise
Direction hospitalière	Piloter l'activité et la qualité des soins	Fine, par service et par jour
Recherche clinique	Décrire des cohortes de patients	Agrégée, jamais individuelle

Six indicateurs sont nommés : durée moyenne de séjour par service, passages aux urgences par jour, taux de ré-admission à 30 jours, relevés de constantes en alerte, prévalence par pathologie, distribution par âge et sexe. Le § 4 du sujet ajoute une septième ligne, ouverte — « toute autre vue d'activité pertinente » — que quatre vues complémentaires remplissent : occupation, mortalité, case-mix, origine géographique.

Les six se calculent depuis la couche `gold`, et `tests.verifier_indicateurs` les restitue à chaque exécution — la valeur obtenue **et** la propriété qui la fonde. Un chiffre qui s'affiche ne prouve rien par lui-même : ce qui le rend opposable, c'est que son dénominateur, son périmètre et ses seuils soient vérifiés en même temps que lui. Les valeurs constatées sur le dépôt courant figurent au § 2.10.

Chaque public reçoit désormais ses indicateurs par un tableau de bord Metabase qui lui est propre — « Pilotage hospitalier » pour la direction, « Recherche clinique » pour la recherche — provisionné par `eds.restitution` (§ 1 du sujet). Aucun réglage de l'outil de restitution n'intervient dans le cloisonnement : chaque tableau de bord interroge la couche `gold` à travers le compte ClickHouse borné de son usage, et c'est ce compte, pas Metabase, qui prononce le refus si une carte tentait d'atteindre l'autre base. Le choix de l'outil et la façon dont il s'articule au cloisonnement sont détaillés au § 2.11.

1.1 Les sources fournies

Le CHU dépose chaque jour ses exports dans un espace en **lecture seule** (`source-filestorage/`), dans trois formats différents. Vingt-huit jours de dépôt sont disponibles, du 1er au 28 août 2026.

Source	Format	Dépôts	Volume brut	Ce qu'elle porte
patients	CSV	3 jours	18 000 lignes → 6 000 patients	patient_id, nir, nom, prenom, birth_date, sex, region_code — l'identité réelle
sejours	CSV	28 jours	6 797 séjours	stay_id, patient_id, service_code, admission et sortie, modes d'entrée et de sortie
diagnostics	JSON imbriqué	28 jours	6 797 objets → 12 720 codes	un à trois codes CIM-10 par séjour, typés principal ou associe
monitoring	Parquet	28 jours	41 778 relevés	constantes au chevet — fréquence cardiaque, saturation, température. La source volumineuse
referentiels	CSV	1er jour	8 services · 13 codes CIM-10	nomenclatures : code → libellé

Quatre traits de ces sources ont déterminé l'architecture, et aucun n'est annoncé par le cahier des charges — ils ont été découverts en les profilant (§ 2.1). Le détail chiffré de ce profilage, anomalie par anomalie, est dans [exploration/RAPPORT-EXPLORATION.md](#).

La complétude n'est pas uniforme. Le monitoring ne couvre que **12,8 % des séjours**, et seulement deux services sur huit en sont équipés. Ce n'est pas une anomalie à corriger mais un périmètre à énoncer partout où l'indicateur de constantes est diffusé.

La contrainte qui structure tout le projet : il s'agit de données de santé, catégorie particulière au sens de l'article 9 du RGPD. Les fichiers sources contiennent l'identité réelle des patients — nom, prénom, numéro de sécurité sociale, date de naissance complète. La conformité n'est donc pas une couche ajoutée en fin de chaîne : c'est une contrainte de conception présente à chaque étape, et elle explique la majorité des choix ci-dessous.

2. Les choix et leur justification

2.1 Une exploration avant toute décision

Cinq sources ont été profilées avant d'écrire la moindre ligne de pipeline. Ce travail a produit quatre constats qui ont directement déterminé l'architecture, et qu'aucune lecture du cahier des charges ne laissait deviner.

patients est un snapshot cumulatif, les trois autres sources sont des deltas. Chaque fichier journalier de patients contient toute la population connue à date : 18 000 lignes pour 6 000 patients réels. Les séjours, diagnostics et relevés n'apparaissent au contraire qu'une fois. Appliquer la même stratégie d'ingestion aux quatre sources aurait multiplié par 3 tout indicateur rapporté au patient.

Les sources n'ont pas le même calendrier de dépôt. Séjours, diagnostics et relevés sont déposés les 28 jours du mois ; le snapshot **patients** ne l'est que les trois derniers. La population de référence est donc l'**union** des dépôts, et non celui du jour : un séjour du 1er août n'est décrit que par un fichier arrivé 25 jours plus tard. Une lecture jour à jour prendrait ce décalage pour une rupture d'intégrité référentielle.

Le monitoring déborde de son jour de dépôt. Le fichier du 1er août contient des relevés jusqu'au 3, et le décalage se reproduit sur les 28 dépôts. Agréger sur le jour de dépôt attribuerait au 1er des alertes survenues deux jours plus tard : l'agrégation se fait donc sur l'horodatage de la mesure.

Les valeurs aberrantes du monitoring sont une panne de capteur, pas du bruit. Fréquence cardiaque et saturation sont *toujours* invalides ensemble — 858 fois les deux, jamais l'une seule — sur exactement quatre combinaisons de butée : $(0 \text{ ou } 500 \text{ bpm}) \times (0 \text{ ou } 120 \%)$. Le relevé entier est écarté : un capteur déconnecté ne garantit la fiabilité d'aucune de ses mesures.

2.2 La pseudonymisation, au plus tôt possible

Le cahier des charges demande de pseudonymiser « à l'entrée du lake » tout en décrivant par ailleurs le lake comme une « copie brute ». Ces deux exigences sont incompatibles. **Nous avons tranché en faveur de la minimisation RGPD** : le lake contient une copie fidèle mais pseudonymisée.

La transformation s'applique **au fil de la copie, ligne par ligne**. Les identités ne sont donc écrites nulle part — pas même dans un répertoire temporaire — et l'empreinte mémoire ne dépend pas de la taille des fichiers.

Donnée source	Traitement	Justification
patient_id (IPP)	HMAC-SHA256 salé, tronqué à 64 bits	Déterministe pour préserver les jointures, salé parce que l'espace des IPP est énumérable — un SHA-256 nu serait cassable par dictionnaire
nir, nom, pre nom	Supprimés	Directement identifiants, sans usage pour les indicateurs demandés
birth_date	Généralisée à l'année	Aucun indicateur ne requiert la date exacte

Un contrôle automatisé rejoue les **17 384 valeurs identifiantes** de la source contre l'intégralité du lake et échoue si l'une d'elles y apparaît. Il vérifie également l'absence de collision de pseudonyme et la préservation des jointures.



Le contrôle le plus direct, exécuté avec le compte d'administration qui voit tout : aucune colonne `nir`, `nom`, `prenom`, `birth_date` ni `patient_id` ne subsiste nulle part dans l'entrepôt. `empty result` — et ce n'est pas un périmètre restreint qui le produit, c'est `system.columns` interrogé sur toutes les bases.

2.3 Un cloisonnement physique, pas conventionnel

Le sujet définit **deux publics** et ce que chacun doit voir : au pilotage la durée de séjour, l'activité des urgences, la réadmission et la surveillance des constantes ; à la recherche la prévalence par pathologie et la description de cohorte. Il en tire une contrainte explicite — « pilotage et recherche ne voient pas les mêmes données → droits d'accès distincts ».

Un filtre applicatif serait contournable par quiconque écrit sa propre requête. Nous avons donc séparé **physiquement** : deux bases ClickHouse, deux comptes de lecture, des droits disjoints.

Quatre comptes ClickHouse, aux vocations distinctes :

Compte	Vocation	Ce qu'il peut atteindre
<code>eds_admin</code>	Exécuter le pipeline — créer les tables, appliquer les habilitations	Tout. C'est le compte du traitement, pas un compte d'usage
<code>eds_pilotage</code>	Direction hospitalière — piloter l'activité et la qualité des soins	17 colonnes de <code>gold_pilotage</code> . Rien d'autre
<code>eds_recherche</code>	Recherche clinique — décrire des cohortes, sous contrainte de petits effectifs	Les deux tables d'agrégats de <code>gold_recherche</code> . Rien d'autre
<code>eds_exploitation</code>	Investigation technique — incident, piste d'audit, demande d'effacement	<code>bronze</code> , <code>silver</code> , <code>quarantaine</code> , <code>ops</code> — en lecture seule

Le compte d'investigation n'est pas une commodité technique. Dans un entrepôt de données de santé, quelqu'un doit pouvoir **remonter à la ligne d'origine** — pour diagnostiquer un incident, produire une piste d'audit, ou exécuter une demande d'effacement au titre du RGPD. C'est précisément ce que les colonnes `_fichier_source` et `_run_id` rendent possible. Ni le pilotage ni la recherche n'atteignent ce détail, fût-il pseudonymisé : eux n'ont accès qu'à gold, et seulement à leur base.

Ce compte mérite d'être justifié. L'administration aurait pu investiguer avec le compte du pipeline, qui a tous les droits. Nous ne l'avons pas fait : `eds_admin` peut créer et supprimer des bases, et ce pouvoir n'a pas sa place dans un usage quotidien, où une requête maladroite suffirait. Le compte d'exploitation applique le moindre privilège — il lit tout ce qui est nécessaire à une investigation, et le moteur lui refuse toute écriture.

Les droits sont posés colonne par colonne, pas base par base. C'est la conséquence directe du choix d'un modèle en étoile : la couche gold contenant les faits au grain de l'événement, un `GRANT` sur la base entière donnerait au pilotage l'accès à `patient_pseudo` et à `stay_id`. Or la direction consulte des indicateurs d'activité — elle n'a jamais à désigner un patient ni à relier deux séjours.

`eds_pilotage` ne dispose donc que des **17 colonnes** que ses indicateurs utilisent : codes de service, dates, tranches d'âge, durées et drapeaux d'alerte. Ni le pseudonyme, ni l'identifiant de séjour, ni les horodatages précis, ni les constantes brutes ; `dim_patient` et `fact_diagnostic` ne lui sont pas accordées du tout. Vérifié : il ne peut ni lire le pseudonyme, ni dénombrer des patients, ni exécuter un `SELECT *` — et il calcule sans difficulté la DMS, les passages aux urgences et les relevés en alerte.

Top screenshot: Query executed successfully. The interface shows the URL `http://localhost:8123`, version `v25.8.33.6`, and uptime `3 hr`. The query `SELECT service_code, duree_jours FROM gold_pilotage.fact_sejour LIMIT 5;` was run, resulting in 5 rows. The table below shows the results:

#	service_code	duree_jours
1	CARDIO	6.291666666666667
2	CARDIO	4
3	CARDIO	2.7916666666666665
4	CARDIO	6.625
5	CARDIO	2.125

Bottom screenshot: Query execution failed. The interface shows the URL `http://localhost:8123`, version `v25.8.33.6`, and uptime `3 hr`. The query `SELECT patient_pseudo FROM gold_pilotage.fact_sejour LIMIT 5;` was run, but an error occurred: `Code: 497. DB::Exception: eds_pilotage: Not enough privileges. To execute this query, it's necessary to have the grant SELECT(patient_pseudo) ON gold_pilotage.fact_sejour. (ACCESS_DENIED) (version 25.8.33.6 (official build))`.

Le même compte, la même table, et une colonne refusée. Le moteur nomme précisément ce qui manque — `grant SELECT(patient_pseudo) ON gold_pilotage.fact_sejour` — ce qui rend la borne vérifiable plutôt que déclarative. Un `GRANT` posé base par base n'aurait pas produit ce refus.

Cette borne ne dépend pas de qui interroge, mais du compte employé. Quiconque se connecte avec `eds_pilotage` — administrateur compris — se voit opposer le même refus, prononcé par le moteur.



La même session, deux requêtes : l'une passe, l'autre est refusée en `ACCESS_DENIED`. Aucune application n'intervient entre les deux — c'est la console SQL de ClickHouse.

C'est ce qui distingue un cloisonnement d'un réglage d'interface : l'outil de restitution branché sur ces bases — Metabase, § 2.11 — hérite de la borne sans pouvoir la contourner, quels que soient ses propres réglages. Ce n'est plus une intention : chaque public **reçoit désormais ses indicateurs par un tableau de bord Metabase dédié**, et la borne que l'interface applique est celle du compte ClickHouse qu'elle emploie, jamais un paramètre posé dans Metabase lui-même.

Ce choix conduit à faire des indicateurs des **tables matérialisées et non des vues**. Une vue ordinaire s'exécute en ClickHouse avec les droits de l'appelant : une vue gold obligerait à ouvrir aussi l'accès à silver, et le cloisonnement s'effondrerait. Le moteur sait, depuis la version 24.4, déclarer une vue `SQL SECURITY DEFINER` qui s'exécute avec les droits de son créateur ; cette alternative a été écartée pour une autre raison — un indicateur recalculé à chaque lecture n'est pas un instantané, et c'est l'instantané qui rend possible le contrôle de `tests.verifier_indicateurs`, qui confronte chaque table au fait dont elle sort.

2.4 Le risque de ré-identification, mesuré puis corrigé

La généralisation à l'année demandée par le sujet **ne suffit pas**. Mesure du k-anonymat sur les quasi-identifiants restants :

Granularité de l'âge	Population à $k \geq 5$	Patients uniques	Cohortes sous le seuil
Année de naissance	62,3 %	185	95
Tranche de 10 ans	100 %	0	13

D'où la règle retenue : l'année n'existe qu'en pilotage, accès restreint ; la base recherche n'expose que des tranches de dix ans. Le filtre des petits effectifs (≥ 5 patients) est appliqué à l'écriture, de sorte qu'aucune donnée sous le seuil n'existe dans cette base — il n'y a rien à penser à masquer au moment de la lecture.

La généralisation seule ne suffit pas, et les données le montrent. Les tranches de dix ans ramènent toute la population à $k \geq 5$, mais **treize cohortes restent sous le seuil** : la nomenclature comporte trois pathologies rares — mucoviscidose, amyotrophie spinale, trisomie 21 — dont les effectifs sont faibles quelle que soit la granularité de l'âge. C'est le filtre à l'écriture, et lui seul, qui garantit la propriété.

Ce filtre se déclenche donc sur les données réelles. Deux prévalences sont supprimées à la construction — trisomie 21 (3 patients) et mucoviscidose (4) — ainsi que treize cohortes de description : elles existent au grain du fait en pilotage, elles n'atteignent pas `gold_recherche . tests.demontrer effectifs` va plus loin et fabrique le cas limite que les données ne fournissent pas — une pathologie portée par exactement 4 patients, une autre par exactement 5 — reconstruit silver et gold, et constate où tombe la coupe : la première est retenue, la seconde passe. Le seuil coupe bien *sous* 5, et non à 5, comme le demande le §5.

2.5 Un modèle en étoile, et un catalogue de KPI

Le § 6 décrit gold comme des « indicateurs par usage » — une table par indicateur. C'est le chemin de lecture le plus direct, et il correspond au besoin courant : la direction consulte une DMS, elle ne compose pas une requête. Mais pris seul, ce raccourci a un défaut rédhibitoire : **il fige les questions**. Croiser la durée de séjour par service *et* par tranche d'âge, ou la ventiler par pathologie, exige d'avoir anticipé la combinaison exacte et d'ajouter une table.

Nous avons donc fait les deux, dans cet ordre de dérivation :

Niveau	Contenu	Pour qui
Indicateurs agrégés	8 tables <code>kpi_*</code> : DMS, urgences, réadmission, alertes, occupation, mortalité, case-mix, origine géographique	La lecture courante — un indicateur, une table, aucune jointure
Modèle en étoile	3 faits, 3 dimensions conformes	L'analyse qu'aucune table figée ne couvre

Les huit tables d'indicateurs sont **dérivées des faits**, jamais de silver. Un indicateur et le fait dont il sort doivent donner le même chiffre par construction — et `tests.verifier indicateurs` confronte chaque table à son recalcul depuis les faits, en cardinalité comme en valeur. Sans ce contrôle, une table d'agrégat continuerait de servir un chiffre que plus rien ne fonde.

Chaque table porte son **effectif** à côté de sa mesure. Un taux sans son dénominateur ne s'interprète pas : 23,5 % d'alertes sur 34 relevés et 7,5 % sur 252 ne pèsent pas de la même façon — c'est exactement le cas qui se présente au dernier jour de la série, quand le dépôt s'amenuise.

L'étoile, sous les indicateurs : trois tables de faits, à trois grains distincts, partageant des dimensions conformes.

Fait	Grain	Volume
<code>fact_sejour</code>	un séjour	6 729
<code>fact_diagnostic</code>	un code posé lors d'un séjour	12 720
<code>fact_releve</code>	une mesure au chevet	40 920

Dimensions : `dim_patient`, `dim_service`, `dim_cim10`.

erDiagram

```
dim_patient ||--o{ fact_sejour      : "patient_pseudo"
dim_service ||--o{ fact_sejour      : "service_code"
dim_patient ||--o{ fact_diagnostic : "patient_pseudo"
dim_cim10   ||--o{ fact_diagnostic : "code_cim10"
dim_service ||--o{ fact_diagnostic : "service_code"
dim_patient ||--o{ fact_releve      : "patient_pseudo"
dim_service ||--o{ fact_releve      : "service_code"
```

```
dim_patient {
    string patient_pseudo PK "pseudonyme HMAC salé"
    int    birth_year "annee seule, Nullable si illisible en source"
    string sexe
    string region
}
```

```
dim_service {
    string service_code PK
    string service "libellé"
}
```

```
dim_cim10 {
    string code_cim10 PK
    string pathologie "libellé"
}
```

```
fact_sejour {
    string stay_id PK "GRAIN 1 sejour - 6729"
    string patient_pseudo FK
    string service_code FK
    date   date_admission "axe temporel"
    string tranche_age "attribut du fait"
    float  duree_jours "MESURE NULL si en cours"
    uint8  est_urgence "MESURE"
    uint8  est_sejour_index "MESURE denominateur ajuste"
    uint8  suivi_readmission_30j "MESURE numerateur ajuste"
    uint8  readmission_30j_brute "MESURE numerateur reference (intervenant)"
}
```

```
fact_diagnostic {
    string stay_id "GRAIN 1 code pose - 12720"
    string patient_pseudo FK "recopie depuis silver.diagnostics, pas une jointure"
    string code_cim10 FK
    string service_code FK "recopie depuis silver.diagnostics"
    date   date_admission "Nullable - axe temporel, recopie"
    uint8  est_principal "MESURE"
    uint8  sejour_coherent "1 si sejour present dans silver.sejours"
    string tranche_age "derive contre dim_patient"
    string sexe "derive contre dim_patient"
}
```

```
fact_releve {
    string stay_id "GRAIN 1 mesure - 40920"
    string patient_pseudo FK "recopie depuis silver.monitoring, pas une jointure"
    string service_code FK "recopie depuis silver.monitoring"
    date   date_mesure "axe temporel - la mesure jamais le depot"
    int    heart_rate "MESURE"
    int    spo2 "MESURE"
    float  temp_c "MESURE"
```

```

uint8 en_alerte "MESURE"
uint8 sejour_coherent "1 si sejour present dans silver.sejours"
}

```

Pourquoi trois faits et non un seul. Les grains sont incompatibles : un séjour porte 1 à 3 diagnostics et 0 à n relevés. Les fusionner en une table unique multiplierait les lignes et fausserait toute somme — c'est le *fan trap* classique. Une DMS calculée sur une table jointe aux relevés compterait chaque séjour autant de fois qu'il a de mesures.

Deux dénormalisations assumées. `fact_diagnostic` porte le pseudonyme patient, son âge et son sexe, recopiés depuis le séjour : les questions de recherche portent sur des cohortes de patients par pathologie, et cette copie leur évite deux jointures systématiques. De même, le drapeau de réadmission est calculé **une fois** dans `fact_sejour` plutôt que laissé à l'outil de restitution : c'est une auto-jointure, hors de portée d'une requête d'analyse ordinaire.

Les faits se construisent sur les dimensions. Les trois dimensions sont écrites en premier ; les faits ensuite, et tout attribut de dimension dont un fait a besoin est lu **dans la dimension**, jamais re-dérivé depuis silver. C'est ce qui fait de l'étoile un modèle plutôt que trois tables qui se ressemblent, et c'est ce qui rend l'intégrité vérifiable : sept contrôles `fait → dimension` s'exécutent à chaque passage de `tests.verifier qualite`.

Le choix a une conséquence pratique : `fact_diagnostic` lit le sexe dans `dim_patient` et non dans `silver.patients`. L'attribut n'a qu'une source de vérité, et le jour où la dimension évolue — historisation, correction — les faits suivent sans qu'on ait à y penser.

Nuance à énoncer : `fact_diagnostic` et `fact_releve` ne rejoignent plus `silver.sejours`, ni `dim_service`, pour leurs attributs porteurs. Depuis la décision de l'intervenant sur la cohérence temporelle (§ 2.8), un diagnostic ou un relevé n'a plus besoin d'un `INNER JOIN silver.sejours` pour connaître son patient, son service et son admission : `silver.diagnostics` et `silver.monitoring` les portent déjà, enrichis **en silver**, contre `bronze.sejours`. Gold les recopie donc tels quels — `patient_pseudo`, `service_code`, `admission_ts` — sans les relire dans une dimension ni les rejoindre à `silver.sejours`. Le seul appariement de dimension qui subsiste au grain de l'événement est le `LEFT JOIN dim_patient` de `fact_diagnostic`, pour `age_au_sejour` et `sexe` ; `fact_releve` ne porte ni l'un ni l'autre et n'est joint à aucune dimension.

L'âge est un attribut du fait, dérivé contre la dimension. `dim_patient` ne porte pas d'âge : celui-ci dépend de la date de l'événement. Mais il ne se calcule pas non plus en silver, où on l'aurait figé trop tôt : `age_au_sejour` croise `dim_patient.birth_year` et l'axe `date_admission` du fait, au moment où le fait est construit. C'est la définition même d'un attribut dérivé de fait — ni une propriété de la personne, ni une donnée de la source.

La jointure est un `LEFT JOIN` volontaire. Un séjour dont le patient serait absent de la dimension doit rester dans le fait avec un âge `NULL`, jamais disparaître : c'est la même règle que partout ailleurs ici — on écarte explicitement, on ne perd pas silencieusement.

Ce que compte une cohorte : tous les types de diagnostic, le principal en complément. Chaque séjour porte un diagnostic principal et 0 à 2 associés — 6 797 principaux (un par séjour, y compris les 68 aux dates incohérentes, cf. § 2.8) contre 5 923 associés. `coh_prevalence.nb_patients` — la colonne de **référence**, celle qui porte désormais le filtre des petits effectifs — compte les patients distincts portant un code CIM-10 donné, **quel que soit son type** : motif d'hospitalisation ou comorbidité. C'est la définition retenue par l'intervenant, et c'est elle qui détermine ce qui est diffusé. Sur l'insuffisance cardiaque (I50), par exemple : 729 patients hospitalisés pour ce motif, **2 156** si l'on compte aussi ceux qui la portent en comorbidité — près du triple, et c'est ce second chiffre qui est publié au § 2.10.

`coh_prevalence.nb_patients_principal` reste exposée à côté, en complément : c'est l'**ancienne** définition de ce projet, restreinte au motif d'hospitalisation seul, toujours pertinente pour qui veut la prévalence au sens strict — mais elle ne détermine plus la diffusion.

La description de cohorte, elle, garde le grain du diagnostic principal. `coh_description` (âge × sexe) continue de filtrer `est_principal = 1` : croiser âge et sexe a un sens univoque sur le motif d'hospitalisation, moins sur une liste de comorbidités où un même patient apparaîtrait potentiellement dans plusieurs cellules d'une même pathologie.

Ce choix n'est pas neutre sur le chiffre obtenu : il doit donc accompagner l'indicateur partout où celui-ci est diffusé, et pas seulement figurer ici. Un indicateur dont on ne dit pas ce qu'il compte n'est pas exploitable — c'est le « justifier chaque chiffre » du § 4 du sujet. Le détail par type de diagnostic reste disponible en pilotage, où `fact_diagnostic` porte `est_principal`.

Le prix de ce choix. Les faits sont au grain de l'événement et portent le pseudonyme patient. Ils ne peuvent donc pas être exposés à la recherche, qui pourrait y reconstituer des cohortes sous le seuil. Ils vivent dans `gold_pilotage`, dont l'accès est restreint ; la recherche reçoit des agrégats dérivés de ces mêmes faits. C'est un arbitrage entre liberté d'analyse et exposition, tranché différemment selon le public.

2.6 Le traitement s'exécute dans le moteur

Le lake est monté en lecture seule dans ClickHouse, qui lit lui-même les fichiers CSV, JSON et Parquet via `file()`. **Python n'envoie que du SQL** : aucune donnée ne transite par sa mémoire. C'est l'inverse de l'anti-pattern qui consiste à extraire les données pour les transformer avec pandas.

2.7 Incrémental en amont, recalcul en aval

Bronze est partitionné par jour de dépôt : rejouer un jour supprime sa partition et la réécrit, sans toucher aux autres. Silver et gold sont au contraire **recalculés intégralement** à chaque exécution — 0,12 seconde à ce volume.

Ce choix garantit qu'un rejeu produit exactement le même état, avec un mécanisme explicable en une phrase. Sa limite est réelle et assumée : il ne tiendrait pas sur plusieurs années d'historique (voir § 3.3).

2.8 Rien n'est perdu silencieusement

Décision de l'intervenant : la cohérence temporelle d'un séjour n'écarte plus ses diagnostics ni ses relevés.

Un séjour dont `discharge_ts < admission_ts` est toujours écarté de `silver.sejours` (règle du §3) — mais cette anomalie porte sur **deux colonnes de la table `sejours`**, et ne dit rien de la validité d'un code CIM-10 posé pendant ce séjour, ni d'une mesure prise au chevet du patient : ce sont des faits médicaux distincts, sur d'autres tables. Le calquer sur ces deux tables ferait porter à une donnée clinique valide l'anomalie d'une autre colonne, sur une autre ligne.

En conséquence, `silver.diagnostics` et `silver.monitoring` lisent désormais `bronze.sejours` directement — jamais `silver.sejours` — pour s'enrichir du patient, du service et de l'admission porteurs, et ne consultent `silver.sejours` que pour poser un drapeau `sejour_coherent` (1 si le séjour y figure), **jamais pour filtrer**. Le diagnostic ou le relevé d'un séjour incohérent est donc **conservé** en silver, avec `sejour_coherent = 0`, et recopié tel quel jusqu'en gold (`fact_diagnostic.sejour_coherent`, `fact_releve.sejour_coherent`) — signalé, jamais silencieusement perdu. Seule l'**absence de patient identifié** écarte réellement l'un ou l'autre : séjour introuvable en bronze (motif `sejour_inconnu`) ou pseudonyme vide (motif `sejour_ecarte`) — cf. le détail des motifs plus bas.

Chaque ligne écartée est écrite dans `quarantaine.rejets` avec son motif. La propriété en découle et se vérifie en une requête :

```
sejours      6 729 +    68 = 6 797
diagnostics 12 720 +     0 = 12 720
monitoring   40 920 +   858 = 41 778
```

Le total de la quarantaine monitoring (858) ne porte plus qu'un seul motif, `capteur_hors_plage`. Les motifs `sejour_ecarte`, `sejour_inconnu` et `releve_hors_sejour` valent chacun **0 ligne** sur ce dépôt — ils restent définis et exercés (`tests.demontrer qualite`), mais aucune donnée réelle ne les déclenche ici : aucun `stay_id` de monitoring n'est absent de `bronze.sejours`, aucun `patient_id` n'est vide, et les 520 relevés postérieurs à une sortie de séjour incohérent échappent au contrôle temporel plutôt que de l'enfreindre (cf. § 2.9).

Pour chaque source, **silver + quarantaine = bronze, à la ligne près**. C'est ce qui distingue écarter une donnée de la perdre.

Une ligne fautive n'est pas toujours écartée : elle peut être **corrigée**, lorsque la valeur inutilisable ne porte aucune clé. La colonne `action` du registre sépare les deux issues — `'ecarte'` entre dans l'équation, `'corrige'` est signalée sans être soustraite. Sans cette distinction, corriger une valeur ferait disparaître une ligne du compte, ou bien la correction resterait invisible : les deux sont inacceptables dans un registre d'incidents qualité.

Pourquoi une base à part, et non `silver.rejets`. Deux raisons, et aucune n'est esthétique. D'abord le contrat de la couche : silver signifie « nettoyé, cohérent » ; y loger la table des lignes sales brouille exactement ce que la couche promet, et un `GRANT SELECT ON silver.*` livrait le registre avec les données propres. Ensuite le cycle de vie : ces lignes portent `stay_id` et, dans `detail`, les valeurs brutes fautives — c'est de la donnée de santé pseudonymisée, mais dont la durée de conservation n'est pas celle de l'entrepôt. On purge une quarantaine quand l'incident qualité est instruit, pas quand la donnée expire. Une base distincte permet de lui appliquer sa propre rétention et ses propres droits — et, le jour venu, de la confier à un référent qualité sans lui ouvrir silver.

2.9 Ce qui change à chaque passage de couche

Le sujet demande de « justifier chaque chiffre ». Voici, frontière par frontière, ce que subit la donnée — et l'effet chiffré de chaque opération.

Source → Lake · pseudonymisation

Seules `patients` et `sejours` sont transformées : ce sont les deux seules sources portant de l'identité. Les trois autres sont recopiées à l'octet près.

Opération	Effet
<code>patient_id</code> → <code>patient_pseudo</code>	HMAC-SHA256 salé, tronqué à 64 bits. Appliqué aux deux sources avec le même sel, pour préserver la jointure
<code>birth_date</code> → <code>birth_year</code>	Généralisation. 1933-12-09 devient 1933
<code>nir</code> , <code>nom</code> , <code>prenom</code>	Supprimés — 3 colonnes sur 7 disparaissent de <code>patients</code>
Volumétrie	inchangée : 24 797 lignes entrent, 24 797 sortent

Lake → Bronze · typage et mise en forme tabulaire

Aucune ligne n'est écartée à ce stade. C'est délibéré : on ne peut compter que ce qu'on a laissé entrer.

Opération	Effet
Typage explicite	<code>String</code> → <code>DateTime</code> , <code>UInt16</code> , <code>Decimal(4,1)</code> , <code>LowCardinality</code>
<code>discharge_ts</code> vide → <code>NULL</code>	683 séjours en cours préservés comme tels, et non datés par défaut
Dates lues en mode tolérant	<code>parseDateTimeBestEffortOrNull</code> : une date illisible entre en <code>NULL</code> au lieu de faire échouer le chargement du jour entier. Un drapeau <code>_discharge_illisible</code> distingue « vide, séjour en cours » de « illisible » — que le <code>NULL</code> confondrait
Aplatissement du JSON	6 797 objets imbriqués → 12 720 lignes , une par code posé. Aucune donnée créée ni perdue
Types larges et signés	<code>Int16</code> pour la fréquence cardiaque : les 858 relevés aberrants peuvent entrer et donc être comptés
Partitionnement	Par jour de dépôt — c'est ce qui rend le rejeu d'un jour possible
Ajout de 4 colonnes techniques	<code>_jour_depot</code> , <code>_fichier_source</code> , <code>_ingested_at</code> , <code>_run_id</code>

Bronze → Silver · qualité, déduplication, enrichissement

C'est la seule frontière où des lignes sont écartées, et chacune l'est avec son motif.

Une règle décide de ce qui a le droit d'être ici. Silver applique les règles de **validité** que le sujet fournit — plages physiologiques, cohérence temporelle, déduplication. Les règles **métier**, que le sujet ne fournit pas et qui se paramètrent, appartiennent à gold : les seuils d'alerte et l'âge à l'événement n'y sont donc pas. Cette frontière n'est pas une convention de style, elle se vérifie (`tests.verifier_qualite` échoue si silver recalcule un âge ou une alerte).

Table	Entrée	Sortie	Opération
<code>patients</code>	18 000	6 000	Déduplication du snapshot cumulatif : <code>row_number()</code> sur le jour de dépôt décroissant, la ligne de rang 1 est retenue — 118 patients ont un attribut divergent entre redépôts ; sexe normalisé <code>upper(trim(...))</code> , hors M/F → <code>'inconnu'</code> ; date de naissance illisible → <code>birth_year</code> <code>NULL</code> , ligne corrigée , jamais écartée
<code>sejours</code>	6 797	6 729	–68 incohérences temporelles (<code>discharge_ts < admission_ts</code>), –0 date illisible, –0 patient manquant
<code>diagnostics</code>	12 720	12 720	aucun écart — la cohérence temporelle du séjour porteur n'écarte plus le diagnostic (décision de l'intervenant, § 2.8)
<code>monitoring</code>	41 778	40 920	–858 capteur hors plage, –0 <code>sejour_inconnu</code> , –0 <code>sejour_ecarte</code> (patient manquant), –0 <code>releve_hors_sejour</code> (évalué seulement sur séjour cohérent)
<code>quarantaine</code>	—	926	Toute ligne écartée (<code>action = 'ecarte'</code>) ou corrigée (<code>'corrige'</code>), avec son motif et son détail

Pourquoi `row_number()` et non `argMax` pour déduplicuer les patients. `birth_year` est `Nullable` depuis qu'une date de naissance illisible est corrigée plutôt qu'écartée. Or `argMax(v, t)` ignore les lignes dont l'argument `v` est `NULL` — vérifié sur ClickHouse 25.8 : si la version la plus récente d'un patient porte une année illisible, `argMax` renvoie l'année d'un dépôt *antérieur*, silencieusement. La ligne retenue ne serait alors plus celle du dépôt retenu. `row_number()` classe la **ligne entière** et n'a pas ce défaut : ce qui est `NULL` au rang 1 reste `NULL`.

Les motifs de la quarantaine, un par un — y compris ceux à zéro ligne. Chaque source a ses propres motifs, mutuellement exclusifs entre eux (une ligne n'est jamais comptée deux fois) :

Motif	Source(s)	Sur ce dépôt	Pourquoi il existe malgré son compte
<code>incohérence_temporelle</code>	<code>sejours</code>	68, écartées	<code>discharge_ts < admission_ts</code> — la seule anomalie qui écarte un séjour lui-même
<code>patient_manquant</code>	<code>patients</code> , <code>sejours</code>	0, écartées	<code>patient_id</code> vide en source — la pseudonymisation ne produit pas de hachage bidon, donc un pseudonyme vide ne peut agréger plusieurs lignes sous une fausse personne
<code>capteur_hors_plage</code>	<code>monitoring</code>	858, écartées	FC/SpO2 hors plage physiologique — le marqueur de panne capteur identifié en exploration
<code>sejour_e carte</code>	<code>diagnostics</code> , <code>monitoring</code>	0, écartées	Le séjour porteur a lui-même été écarté pour <code>patient_manquant</code> (pseudonyme vide) — seul cas qui écarte encore un diagnostic ou un relevé
<code>sejour_inconnu</code>	<code>diagnostics</code> , <code>monitoring</code>	0, écartées	<code>stay_id</code> absent de <code>bronze.sejours</code> — aucune trace du séjour porteur, distinct de <code>sejour_ecarte</code> (qui suppose le séjour présent mais son patient absent)
<code>relevés_hors_séjour</code>	<code>monitoring</code>	0, écartées	Horodatage hors de la fenêtre [admission, sortie] d'un séjour cohérent — ne se déclenche jamais sur ce dépôt (cf. plus bas pour les 528 relevés post-sortie, qui échappent à ce contrôle)

Les quatre derniers motifs sont à zéro ligne sur ce dépôt réel, mais ils ne sont pas du code mort : chacun est exercé par `tests.demontrer_qualite`, qui fabrique le cas que la source ne fournit pas (patient manquant, `stay_id` inconnu) et vérifie où tombe la ligne.

Les deux contrôles de format du §3 ne se déclenchent pas sur ces données. « Dates valides » et « sexe normalisé (M/F) » : la source est propre sur les deux — 9 045 M, 8 955 F, aucune date illisible. Les règles sont néanmoins implémentées, et **exercées** : `tests.demontrer_qualite` injecte en bronze sept lignes fautives que la source ne contient pas — dates illisibles, sexe hors nomenclature, casse, pseudonyme vide côté patients et côté séjours — reconstruit silver dessus, et constate le sort de chacune avant de remettre l'entrepôt en état. Une règle qu'aucune donnée n'exerce ne prouve rien.

Ces deux contrôles n'ont pas la même issue, et c'est délibéré :

Anomalie	Issue	Pourquoi
Date d'admission illisible, ou date de sortie non vide et illisible	Écartée	Sans date fiable, ni la durée de séjour ni le rattachement d'un relevé ne tiennent. Le contrôle passe avant la cohérence temporelle : sinon la comparaison porterait sur un NULL et la ligne échapperait aux deux
Sexe hors nomenclature	Corrigée en 'inconnu', ligne conservée et signalée	Écarter le patient orphelinerait tous ses séjours, pour un attribut purement descriptif qui n'entre dans aucune clé

C'est ce que distingue la colonne **action** de la quarantaine. Sans elle, une correction fausserait l'équation de conservation ou resterait invisible.

Colonnes ajoutées par calcul ou par jointure :

Colonne	Origine
duration	dateDiff admission → sortie. NULL si séjour en cours
est_encours	discharge_ts IS NULL
service_label	Jointure avec le référentiel des services
libelle	Jointure avec la nomenclature CIM-10
discharge_mode	Normalisation : '' → 'inconnu' — 683 séjours , tous en cours. Aucun séjour clos n'est privé de mode de sortie dans ce dépôt : la règle est en place, elle n'a ici à traiter que le cas légitime

Les 528 relevés postérieurs à la sortie du patient, et pourquoi 520 d'entre eux ne sont plus écartés. L'exploration (§ 6.3.c) avait repéré 528 relevés de monitoring dont l'horodatage tombe après **discharge_ts**. Le contrôle **releve_hors_sejour** ne s'évalue que pour un séjour **cohérent** — présent dans **silver.sejours** — car sur un séjour dont la sortie précède l'admission, on ne sait pas laquelle des deux dates est fautive, donc pas ce que serait « avant » ou « après ». Sur les 528 : **8** portent en outre des mesures hors plage physiologique et sont déjà écartées par **capteur_hors_plage**, comptées dans les 858 ci-dessus. Les **520** restants portent un séjour **incohérent** : ils échappent au contrôle temporel — non par exemption de règle, mais parce que la règle n'a pas de sens à leur appliquer — et sont **conservés** en **silver.monitoring** avec **sejour_cohérent = 0**. Aucun des 528 n'est donc écarté par **releve_hors_sejour** lui-même sur ce dépôt : c'est ce qui explique son compte à zéro dans le tableau des motifs ci-dessus.

Silver → Gold • modélisation dimensionnelle

Aucune ligne n'est perdue vers **gold.pilotage** : les trois faits reprennent exactement les volumes de silver. La transformation est structurelle.

Opération	Effet
Éclatement en faits et dimensions	4 tables silver → 3 faits + 3 dimensions, les dimensions d'abord
age_au_sejour	toYear(date_admission) - dim_patient.birth_year — dérivé contre la dimension , approximé à l'année
tranche_age	Calculée dans les faits, par tranches de 10 ans
sexe	Lu dans dim_patient, source de vérité unique
alerte_fc, alerte_spo2, alerte_temp, en_alerte	Application des seuils paramétrés (eds/config.py) — règle métier, pas règle de validité
est_urgence	admission_mode = 'urgence'
est_sejour_index	Clos et patient non décédé — dénominateur de la réadmission
suivi_readmission_30j	Auto-jointure résolue une fois , à la construction — dénominateur AJUSTÉ (clos, non décédés)
readmission_30j_brute	Même auto-jointure, dénominateur BRUT (tous les séjours, décès compris) — chiffre de référence de l'intervenant (§ 2.10)
sejour_coherent	Recopié depuis silver.diagnostics / silver.monitoring — jamais un filtre en gold, cf. § 2.8
Dénormalisation	patient_pseudo, service_code, date_admission recopiés tels quels depuis silver.diagnostics / silver.monitoring (déjà enrichis en silver) ; tranche_age, sexe restent dérivés contre dim_patient
Axes temporels	date_admission pour les séjours, date_mesure pour les relevés — la mesure, jamais le dépôt

Puis, **dérivés de ces faits**, les huit indicateurs agrégés du pilotage :

Table	Grain	Lignes	Répond à
kpi_dms_service	service × mois	8	DMS — avec médiane, P90, max, et dms_heures en plus de dms_jours
kpi_urgences_jour	jour d'admission	28	activité des urgences — nb_passages_urgences (référence, service), nb_encore_present, duree_moy_heures, nb_admissions_urgence (mode, complément)
kpi_readmission_service	service	8	réadmission à 30 jours — colonnes brutes ET ajustées côte à côte
kpi_alertes_jour	jour de mesure × service	59	relevés en alerte
kpi_occupation_jour	jour × service	224	« autre vue d'activité »
kpi_mortalite_service	service	8	idem
kpi_casemix_service	service × pathologie	32	idem
kpi_origine_service	service × département	64	idem

Aucune information n'y est créée : ce sont des `GROUP BY` sur les faits, et l'égalité est vérifiée table par table. Chaque expose son effectif à côté de sa mesure, et `kpi_readmission_service` expose numérateur et dénominateur en plus du taux — de quoi recomposer l'indicateur sur un autre périmètre.

Vers `gold_recherche`, en revanche, la réduction reste volontaire, mais sa définition a changé (§ 2.5) :

Opération	Effet
nb_patients (référence)	Aucun filtre de type — tous les diagnostics, principal et associé : 12 720 lignes de faits
nb_patients_principal (complément)	Filtre <code>est_principal</code> : seul le motif d'hospitalisation est retenu — 6 797 diagnostics sur 12 720
Agrégation	12 720 lignes de faits (tous types) → 11 prévalences (<code>coh_prevalence</code>) ; 6 797 diagnostics principaux → 89 cohortes (<code>coh_description</code>)
HAVING >= 5 patients	Filtre appliqué à l'écriture, sur <code>nb_patients</code> : aucune cohorte sous seuil n'existe. Il retire ici 2 prévalences et 13 cohortes
Généralisation de l'âge	Tranches de 10 ans uniquement — <code>birth_year</code> absent
Suppression du pseudonyme	<code>patient_pseudo</code> n'est pas exposé

Bilan

Couche	Lignes	Détail	Ce qu'elle garantit
Lake	24 818 + Parquet	89 fichiers — 3 <code>patients.csv</code> , 28 <code>sejours.csv</code> , 28 <code>diagnostics.json</code> , 28 <code>monitoring.parquet</code> , 2 référentiels	Copie fidèle, sans aucune identité
Bronze	79 316	patients 18 000 · séjours 6 797 · diagnostics 12 720 · relevés 41 778 · référentiels 21	Typé, partitionné, traçable jusqu'au fichier d'origine
Silver	66 369	patients 6 000 · séjours 6 729 · diagnostics 12 720 · relevés 40 920	Nettoyé, cohérent, enrichi — et rien d'autre
Quarantaine	926	toute ligne écartée, avec son motif, son détail et sa provenance	Rien n'est perdu silencieusement
Gold pilotage	66 390	3 faits ($6\,729 + 12\,720 + 40\,920 = 60\,369$) · 3 dimensions (6 021)	Modèle dimensionnel interrogeable librement
Gold recherche	100	prévalences 11 · cohortes 89	Agrégats anonymisés, $k \geq 5$, aucun pseudonyme

2.10 Les six indicateurs, et ce qui les rend opposables

Le § 4 du sujet demande de « justifier chaque chiffre ». Un tableau de bord affiche une valeur ; il ne dit pas sur quel dénominateur elle est calculée, ni si le périmètre annoncé est celui qui a servi. `tests.verifier indicateurs` restitue donc les six valeurs **et** les propriétés qui les fondent, dans la même exécution : si l'une tombe, le chiffre affiché à côté est faux, et le contrôle échoue avant qu'il ne soit diffusé.

Indicateur	Valeur sur le dépôt courant	Ce qui est vérifié en même temps
DMS par service	2,15 j (Urgences) à 9,05 j (Réanimation), sur 6 046 séjours clos — <code>dms_heures</code> désormais disponible (51,7 h à 217,1 h)	Les 8 services du référentiel sont représentés ; le dénominateur est exactement l'ensemble des séjours clos ; aucune durée manquante parmi eux ; <code>dms_heures</code> coïncide avec <code>dms_jours × 24</code> à ±0,2 h (double arrondi)
Passages aux urgences par jour	1 423 passages (<code>service_code = 'URGENCE S'</code> , référence) sur 28 jours, 9 à 82 par jour ; jusqu'à 18 encore présents un jour donné ; durée moyenne 46,0 à 60,3 h. <code>nb_admissions_en_urgence</code> (mode d'admission, tous services) : 3 327, en complément	La série journalière somme au total ; l'axe est la date d' admission , jamais le jour de dépôt ; <code>nb_encore_presents</code> ne compte que des séjours sans date de sortie ; les deux lectures — service et mode — coexistent sans se confondre
Réadmission à 30 jours	11,59 % — 780 réadmissions sur 6 729 séjours (BRUT, référence de l'intervenant) ; 12,81 % — 647 sur 5 051 séjours index (AJUSTÉ, décès exclus, complément documenté)	Le numérateur est inclus dans le dénominateur, dans les deux définitions ; aucune réadmission portée par un séjour hors dénominateur ; le brut confronte directement <code>sum(readmission_30j_brute)</code> à <code>count()</code> sur <code>fact_sejour</code>
Relevés en alerte	3 314 sur 40 920 (8,1 %) — FC 1 105 · SpO2 1 127 · T° 1 082, seuils FC < 50 ou > 100 bpm	<code>en_alerte</code> est bien la réunion des trois motifs ; les drapeaux sont recalculés depuis <code>eds/config.py</code> et doivent coïncider — ce qui prouve que le seuil configuré est celui qui a servi, et non une constante figée dans le SQL
Prévalence par pathologie	11 pathologies, <code>nb_patients</code> (référence, tous types) de 8 à 2 234 patients ; <code>nb_patients_principal</code> (complément, motif seul) de 8 à 729	L'agrégat reproduit exactement le recalcul depuis <code>fact_diagnostic</code> , sans filtre de type pour <code>nb_patients</code> ; <code>nb_sejours >= nb_patients</code> ; toute pathologie restituée existe dans la nomenclature
Distribution âge × sexe	89 cohortes, tranches 0-9 à 90-99	Aucune tranche <code>inconnu</code> ; sexe borné à la nomenclature ; la somme des cases d'une pathologie ne dépasse pas <code>nb_patients</code> (référence) de la prévalence ; aucune pathologie décrite hors prévalence

Les quatre vues du cinquième point. Le § 4 du sujet laisse une ligne ouverte après les quatre indicateurs nommés. Quatre vues la remplissent, chacune répondant à une question qu'aucune des quatre ne pose :

Vue	Valeur sur le dépôt courant	Ce qui est vérifié en même temps
Occupation	Cardiologie 352 présents en moyenne, pic à 473 ; 28 jours couverts	Chaque séjour compte une admission et une seule ; les sorties observées correspondent aux séjours clos dans la fenêtre ; jamais moins de présents que d'admis ; la série ne déborde pas la fenêtre d'observation
Mortalité	Pédiatrie 19,64 %, réanimation 18,2 % — chiffres non interprétables , voir ci-dessous	Le dénominateur est restreint aux séjours clos ; la table coïncide avec le fait
Case-mix	Pneumologie : 69,33 % de pneumopathies ; Urgences : 56,75 % d'infections urinaires	Les parts d'un même service somment à 100 % ; la table couvre tous les diagnostics principaux, y compris ceux des 68 séjours aux dates incohérentes
Origine géographique	8 départements de résidence par service, répartition assez plate (13,3 à 16,3 % pour le département le plus représenté d'un service)	Les parts d'un même service somment à 100 % ; <code>region_code</code> n'est retenu jusqu'en gold que parce que cette vue l'utilise — sinon la minimisation l'aurait exclu

La mortalité est publiée mais ne doit pas être lue. Sur les données fournies, les modes de sortie sont uniformément distribués : il en résulte 19,6 % de décès en pédiatrie, ce qu'aucun établissement réel ne présenterait. L'indicateur est juste — il coïncide avec le fait, son dénominateur est le bon — mais la donnée qui l'alimente ne l'est pas. Il figure pour la complétude de la vue métier, avec cette réserve attachée. C'est précisément le cas où « justifier chaque chiffre » consiste à dire qu'un chiffre ne vaut rien.

La dispersion des durées corrige un angle mort. `kpi_dms_service` porte désormais médiane, P90 et maximum à côté de la moyenne. En réanimation : moyenne 9,05 jours, médiane 8,21, **P90 à 18,03**. Publier la seule moyenne masquait la moitié de l'écart entre un séjour ordinaire et un séjour long — soit exactement ce qu'un service qui pilote ses lits a besoin de voir.

Chaque indicateur du pilotage existe en deux exemplaires, et c'est délibéré : la table agrégée, qui est le chemin de lecture, et le fait, qui est la source de vérité. Un cinquième contrôle par indicateur confronte les deux — même nombre de lignes, mêmes valeurs. C'est ce qui empêche une table d'agrégat de dériver en silence après un changement de règle appliqué d'un seul côté.

Le contrôle le plus utile est celui des seuils d'alerte. Ils sont présentés comme un paramètre d'exploitation, surchargeable par l'environnement sans toucher au SQL (§ 3.3). Cette affirmation serait invérifiable si le contrôle se contentait de compter les alertes : recalculer les drapeaux à partir de la valeur lue dans la configuration, et exiger l'égalité, est ce qui transforme la promesse en propriété. Changer `EDS_SEUIL_FC_BASSE` et relancer déplace les deux côtés de l'égalité ensemble ; laisser un seuil en dur dans le SQL les ferait diverger.

Un cinquième contrôle, d'une nature différente : la confrontation aux valeurs de référence de l'intervenant. Tout ce qui précède prouve des *propriétés* — équation de conservation, cohérence table ↔ fait, inclusion numérateur/dénominateur. Une propriété peut tenir alors que la *valeur* publiée n'est pas celle attendue : un dénominateur mal choisi peut rester cohérent avec lui-même sans être le bon. `tests.verifier_conformite` confronte donc directement l'entrepôt à des valeurs de référence fournies par l'intervenant — comptages exacts pour les effectifs, tolérance $\pm 0,1$ pour les moyennes (DMS, durées) — sur silver et sur les six indicateurs. C'est la seule section qui peut échouer sur une valeur juste alors que toutes les propriétés tiennent, et c'est voulu : c'est elle qui fait foi sur les définitions retenues dans ce rapport (§ 2.5, § 2.10). Le fichier de référence est **local, non versionné** (`eds-chu-sujet/`, exclu par `.gitignore`) : absent sur une machine qui ne l'a pas reçu, la section s'annonce ignorée plutôt que d'échouer, pour ne pas bloquer le reste de la suite.



Ce que ces contrôles ne remplacent pas. Ils établissent qu'un indicateur est calculé sur le périmètre annoncé, pas qu'il soit cliniquement pertinent. Les réserves du § 3.3 — historique de 28 jours pour un indicateur à 30, monitoring limité à deux services, données synthétiques — restent entières et doivent accompagner chaque chiffre là où il est diffusé.

2.11 La restitution, et pourquoi elle n'affaiblit pas le cloisonnement


Le § 1 du sujet demande une interface — au moins deux tableaux de bord, pilotage et recherche, avec démonstration du cloisonnement des droits — et conseille Metabase. `eds/restitution.py` la provisionne intégralement par son API REST : deux connexions ClickHouse, deux groupes, trois comptes applicatifs, un graphe de permissions et les deux tableaux de bord, jamais posés à la souris. Quatre choix méritent d'être justifiés séparément.

Metabase, sans code applicatif. Le sujet le conseille explicitement, et il correspond exactement au besoin : deux publics qui consultent des indicateurs déjà agrégés, jamais une équipe qui développerait une interface sur mesure. Aucune ligne de code métier ne s'ajoute au projet — le module qui le provisionne parle HTTP, pas une API de rendu — ce qui laisse la totalité de l'effort d'ingénierie sur l'entrepôt, où se joue réellement le cloisonnement.


Chaque connexion Metabase s'authentifie avec le compte ClickHouse borné de son usage — `eds_pilotage` ou `eds_recherche` — jamais avec un compte unique. L'alternative la plus simple à écrire aurait été une seule connexion administrateur, puis un filtrage applicatif dans Metabase (permissions par groupe, par collection). Elle est écartée pour la même raison que le § 2.3 écarte un filtre applicatif au niveau SQL : elle serait contournable par quiconque atteint l'API Metabase avec des droits suffisants, ou par une mauvaise manipulation du graphe de permissions. En branchant chaque connexion sur le compte déjà borné par `sql/50_droits.sql`, le refus qu'un utilisateur de Pilotage rencontre sur la base Recherche n'est pas un réglage de plus à maintenir en cohérence avec ClickHouse : c'est le **même** refus, prononcé par le **même** moteur, qu'on interroge en SQL direct ou depuis un tableau de bord. `tests.demontrer restitution` le prouve en forçant, avec le compte **administrateur** Metabase, une requête native sur la mauvaise base à travers chacune des deux connexions : le refus renvoyé porte le message ClickHouse lui-même (« Not enough privileges... ACCESS_DENIED »), pas un message Metabase — la preuve que même le compte le plus privilégié de l'interface ne franchit pas la borne.



Les deux vues vont par paire, et c'est la paire qui prouve quelque chose : le compte nommé en tête de page ne voit, dans sa barre latérale, que sa propre collection. Une seule des deux captures laisserait penser que la collection absente n'est peut-être pas épinglée.



Forcer l'adresse du tableau de bord étranger ne contourne rien. Ici c'est Metabase qui refuse — la capture suivante montre que le moteur refuse aussi, indépendamment.




La démonstration décisive. Le compte recherche compose une question SQL native sur `gold_pilotage.fact_sejour` : le message affiché est celui de ClickHouse, « eds_recherche: Not enough privileges... ACCESS_DENIED », pas un message Metabase. Le panneau de droite ajoute une confirmation : la connexion Recherche n'expose que 2 tables, les deux tables d'agrégats — le reste de l'entrepôt n'existe pas pour elle.

Chaque question du tableau de bord est du SQL natif (`dataset_query.type = "native"`), jamais le query-builder graphique de Metabase. Un query-builder recompose une requête à partir de clics, avec un SQL généré qu'il faut relire pour être sûr qu'il interroge la bonne table et le bon filtre. Une question SQL native se lit directement dans `eds/restitution.py`, se rejoue à la main dans la console ClickHouse pour vérifier le chiffre affiché, et se provisionne par API sans ambiguïté de traduction. Le chiffre qu'un tableau de bord affiche est donc, à la lettre, celui que renvoie la table gold — jamais une agrégation recomposée côté Metabase à partir d'une lecture plus fine.

Ce que chaque tableau de bord donne à voir. Vingt-deux questions et quatre cartes de texte, réparties en deux vues qui ne partagent aucune donnée.

« Pilotage hospitalier » — 16 questions	Forme
Nombre de séjours · DMS globale · réadmission à 30 j · taux d'alerte · date de dernière construction	cinq compteurs, en tête
DMS par service	barres, plus une table de dispersion (médiane, P90, maximum)
Passages aux urgences (service) et admissions en urgence (mode d'admission)	deux séries journalières distinctes , jamais confondues
Réadmission à 30 jours par service	barres, plus une table exposant numérateur et dénominateur
Relevés de constantes en alerte	série journalière
Occupation par jour et par service	aires empilées
Case-mix et origine géographique par service	deux tables de parts
Mortalité hospitalière par service	barres
« Recherche clinique » — 6 questions	Forme
Pathologies diffusables · effectif total décrit	deux compteurs
Prévalence par pathologie	barres, plus une table opposant l'effectif de référence à celui du seul motif d'hospitalisation
Description de cohorte, âge × sexe	pyramide des âges, plus la table détaillée par pathologie

« Pilotage hospitalier » — les quatre indicateurs nommés du § 4 du sujet et les vues complémentaires. Les réserves sont écrites dans le tableau de bord lui-même, à côté des courbes qu'elles nuancent, et non reléguées dans ce rapport.



« Recherche clinique » — les mêmes données sources, une lecture entièrement différente : des agrégats filtrés au seuil de 5 patients, aucun pseudonyme, l'âge en tranches de dix ans. Les deux vues ne partagent aucune table.

Trois réserves sont écrites dans les tableaux de bord eux-mêmes, pas seulement dans ce rapport : le monitoring ne concerne que deux services, la mortalité n'est pas cliniquement interprétable sur des données synthétiques (§ 2.10), et la base recherche ne diffuse aucune cohorte de moins de cinq patients. Un indicateur voyage sans son dossier : la réserve doit être là où le chiffre est lu, sans quoi elle ne protège personne.

Le provisionnement se fait par API, pas à la souris. Le reste de l'entrepôt (lake → bronze → silver → gold, droits ClickHouse) est entièrement scripté et rejouable ; une restitution posée manuellement dans l'interface aurait rompu cette propriété et ne serait démontrable qu'en capture d'écran. `eds.restitution` pilote Metabase exactement comme `eds.run` pilote ClickHouse : idempotent (recherche par nom avant toute création, mise en page d'un tableau de bord intégralement reposée à chaque passage plutôt qu'accumulée), et vérifié (chaque question est interrogée après coup via `/api/card/:id/query` avant de rendre la main — un tableau de bord silencieusement cassé ne peut pas sortir du provisionnement). Une relance ne change ni le nombre d'objets Metabase ni leur contenu.

3. Architecture, limites et recommandations

3.1 Schéma

```
flowchart TD
    S["source-filestorage/<br/><i>dépôt quotidien du CHU · lecture seule</i><br/>identités en clair"]
    P{{"Pseudonymisation en flux<br/>HMAC salé · généralisation · suppression"}}
    L["lake/<br/><i>copie pseudonymisée</i>"]
    B["<b>bronze</b><br/>tables typées<br/>partitionnées par jour de dépôt"]
    V["<b>silver</b><br/>nettoyé · dédoublé · enrichi"]
    R["<b>quarantaine</b>.rejets<br/><i>926 lignes écartées, motivées</i>"]

    subgraph GP["gold_pilotage – modèle en étoile"]
        direction TB
        DIM["dim_patient · dim_service · dim_cim10"]
        F1["fact_sejour<br/><i>1 séjour</i>"]
        F2["fact_diagnostic<br/><i>1 code posé</i>"]
        F3["fact_releve<br/><i>1 mesure</i>"]
        DIM --> F1
        DIM --> F2
        DIM --> F3
    end

    end

    GR["<b>gold_recherche</b><br/>agrégats · k ≥ 5<br/>tranches de 10 ans"]
    DP["Tableau de bord Metabase<br/><i>« Pilotage hospitalier »</i><br/>connexion eds_pilotage"]
    DR["Tableau de bord Metabase<br/><i>« Recherche clinique »</i><br/>connexion eds_recherche"]
    O["ops.executions<br/>journal d'exécution"]

    S -->|Python, ligne à ligne| P --> L
    L -->|"ClickHouse file()"| B
    B -->|SQL| V
    V -->|règles qualité| R
    V -->|SQL| GP
    F2 -->|agrégation + filtre| GR
    GP --> DP
    GR --> DR
    B --> O
    V --> O
    GP --> O
```

Les identités n'existent que dans la source, fournie et non versionnée. La frontière de pseudonymisation est franchie **une seule fois**, en Python, avant toute écriture persistante.

3.2 Traçabilité

Chaque ligne de bronze et de silver porte **le jour de dépôt, le fichier dont elle provient** et l'identifiant du run qui l'a produite, plus son horodatage — d'ingestion en bronze, de construction en silver. La question « *cette donnée, d'où vient-elle et quand a-t-elle été traitée ?* » se répond donc en une requête, sans jointure entre couches.

La propriété vaut aussi pour ce qui a été **écarté** : `quarantaine.rejets` porte la même provenance. On peut donc remonter d'un problème de qualité au fichier de dépôt qui l'a introduit — c'est ce que demande une investigation réelle.

Trois nuances assumées. En silver, `patients` est une réduction de plusieurs lignes bronze (snapshot cumulatif) : sa provenance est celle de la **version retenue**, d'où les colonnes `_jour_depot_retenu` et `_fichier_source_retenu`. Pour `monitoring`, `_jour_depot` désigne le jour du fichier, jamais celui de la mesure — les deux différents, le flux débordant de son jour de dépôt.

Enfin, les deux **référentiels** (`ref_services`, `ref_cim10`) portent le fichier d'origine mais pas de colonne `_jour_depot`, et ne sont pas partitionnés. Ce ne sont pas des données journalières : ils sont rechargés en entier à chaque exécution, et leur chemin de fichier — `lake/referentiels/2026-08-01/services.csv` — contient déjà le jour. Une colonne de plus n'aurait rien ajouté qu'un doublon.

Gold s'arrête volontairement à `_run_id` et `_built_at`. La provenance fichier y serait inexploitable : le compte de pilotage n'a pas même le droit de lire `stay_id`, et une investigation passe par la connexion d'exploitation, donc par silver et bronze. Ce qu'on veut savoir de gold, c'est quelle exécution l'a produit — pas de quel dépôt vient une moyenne.

La table `ops.executions` enregistre chaque étape — durée, volume, statut, cause d'échec. Aucune donnée de santé n'entre dans ce journal.

3.3 Limites

L'historique de 28 jours tronque encore le taux de réadmission. La fenêtre d'observation reste plus courte que celle de l'indicateur — les délais constatés vont de 3 à 23 jours, et un patient sorti le 28 août ne peut pas être suivi jusqu'au 27 septembre. Le taux de **référence** publié au § 4 du sujet et au § 2.10 est le **BRUT** — 11,59 % (780 réadmissions sur 6 729 séjours, décès compris) : sa définition fait foi (valeurs fournies par l'intervenant), et c'est lui qui subit pleinement la troncature de la fenêtre. Le taux **AJUSTÉ** — 12,81 % (647 sur 5 051 séjours index, décès exclus) — reste exposé en complément documenté : un patient réadmis après un décès enregistré est une incohérence de saisie, mais la référence ne l'exclut pas, d'où deux chiffres plutôt qu'un arbitrage silencieux. Dans les deux cas c'est un **plancher** : l'écart n'est plus que de deux jours, ce qui le rend exploitable comme ordre de grandeur, mais il faut 90 jours pour une tendance.

Le monitoring ne couvre que 12,8 % des séjours, sur deux services (Cardiologie 41,9 %, Réanimation 40,7 % — mesuré sur `silver.sejours`). Les six autres n'ont **aucun** relevé. Les indicateurs de constantes sont explicitement restreints à ce périmètre et ne sont pas extrapolables.

Les seuils d'alerte ne sont pas fournis par le CHU au sens d'une norme clinique, et il n'en existe aucun qui soit réglementaire. Les moniteurs de chevet sortent d'usine avec des valeurs par défaut — chez l'adulte, alarme basse de fréquence cardiaque autour de 50 bpm en avertissement et 40 en critique — que chaque service, puis chaque soignant, sont censés adapter au patient : bêta-bloquants, sportif, nouveau-né. Ce n'est donc pas une propriété de la donnée mais un **paramètre d'exploitation**. Les valeurs par défaut retenues sont désormais celles **fixées par l'intervenant** — FC hors [50, 100] bpm, SpO2 < 92 %, température > 38,5 °C — pour reproduire l'indicateur de référence ; le mécanisme de surcharge est inchangé : elles restent externalisées dans `eds/config.py` et surchargeables par l'environnement (`EDS_SEUIL_FC_BASSE=45`, exemple qui reste distinct des deux bornes par défaut), et doivent être validées médicalement avant tout usage clinique. Avec ces seuils, le taux d'alerte est plat entre les deux services équipés — 8,1 % en Cardiologie, 8,0 % en Réanimation — ce qu'aucune donnée clinique réelle ne présenterait (cf. « données synthétiques » ci-dessous). Le pas suivant, hors périmètre ici faute de source pour l'alimenter, serait un référentiel de seuils **par service** — la réanimation et la médecine n'ont pas les mêmes presets.

Le recalcul intégral de silver et gold ne passera pas à l'échelle. Il est instantané sur 42 000 relevés ; il deviendra le goulot d'étranglement au-delà de quelques dizaines de millions de lignes.

L'âge est approximé à l'année, conséquence directe de la généralisation RGPD. Erreur maximale : un an.

Les données fournies restent synthétiques. Elles portent désormais des écarts plausibles entre services — DMS de 2,15 jours aux Urgences à 9,05 en Réanimation, une gradation cohérente avec la nature des prises en charge — mais elles sont générées, et le taux d'alerte reste, lui, plat (8,1 % en Cardiologie comme en Réanimation). La plateforme restitue fidèlement ce que contiennent les sources ; aucune conclusion médicale ne peut en être tirée.

Les fichiers sources ne sont pas versionnés. Un clone du dépôt ne suffit donc pas à exécuter le pipeline : il faut y placer le dépôt du CHU. C'est un choix délibéré — faire entrer des identités de patients dans un historique Git, d'où elles ne peuvent plus être retirées, serait contradictoire avec l'objet même de ce projet.

Les faits exposent le grain de l'événement au compte pilotage. Le sujet décrit la couche gold comme des « indicateurs par usage » : les huit tables `kpi_*` répondent à cette attente et constituent le chemin de lecture normal. Mais le compte de pilotage conserve aussi l'accès à dix-sept colonnes des faits, si bien qu'il peut composer des croisements qu'aucune table figée ne couvre — au prix d'un accès au grain du séjour.

Cet écart est délibéré : il achète une liberté d'analyse que les indicateurs figés ne permettent pas — croiser la durée de séjour par service *et* par tranche d'âge ne demande aucune table supplémentaire. Les données restent pseudonymisées et l'accès nominatif et restreint.

Et il est désormais réversible sans rien perdre. Depuis que les indicateurs existent en tables, borner `eds_pilotage` aux seules `kpi_*` suffirait à lui retirer tout accès au grain de l'événement : les six indicateurs demandés continueraient de fonctionner, seule la liberté de croisement disparaîtrait. C'est la décision à acter avec le DPO — elle ne coûte plus qu'un `REVOKE`.

Le seuil des petits effectifs protège chaque cellule, pas leur différence. `coh_prevalence` publie l'effectif d'une pathologie et `coh_description` ses cellules âge × sexe au diagnostic principal, chacune filtrée à $k \geq 5$. Les deux tables étant lisibles par le même compte, leur **différence** est calculable : `nb_patients_principal` moins la somme des cellules publiées donne le total des cellules supprimées.

Un cas réel l'illustre sur ce dépôt. L'amyotrophie spinale (G12) est diffusée en prévalence — 8 patients, au-dessus du seuil — mais aucune de ses 7 cellules âge × sexe n'atteint 5 : `coh_description` n'en publie donc aucune, et la soustraction $8 - 0$ révèle que 8 patients se répartissent en cellules toutes inférieures à 5. La borne n'est pas franchie — aucune cellule n'est identifiée, et le total était déjà public — mais la mécanique est là : si **une seule** cellule d'une pathologie était supprimée, la même soustraction en donnerait l'effectif exact. Ce cas-là ne se présente pas ici (les autres pathologies n'ont aucune cellule supprimée), et c'est un hasard des données, pas une garantie du modèle.

Deux réponses possibles, à arbitrer avec le DPO : la **suppression secondaire** — masquer une deuxième cellule dès qu'une première l'est — ou le retrait de `nb_patients_principal` de la base recherche, qui supprime le terme de comparaison. La seconde suffit ici, puisque `nb_patients` (tous types) et `coh_description` (principal seul) ne portent pas sur le même périmètre et ne se soustraient donc pas.

La courbe d'occupation monte artificiellement sur ses premiers jours. Aucun séjour antérieur au 1er août n'est connu : `kpi_occupation_jour` ne compte, ce jour-là, que les 243 séjours admis le jour même, alors qu'un hôpital réel héberge déjà des patients entrés la veille. La montée des premiers jours — 243, puis 463, puis 666 — est donc un artefact d'observation, pas une variation d'activité. La lecture ne devient représentative qu'une fois la fenêtre plus longue que la durée de séjour maximale.

La restitution règle le cloisonnement, pas ce qui l'entoure. Trois limites propres à Metabase, distinctes de celles de l'entrepôt ci-dessus :

- **La base applicative de Metabase (H2, embarquée dans le conteneur) n'est pas adaptée à une mise en production.** Elle convient à une démonstration — un seul fichier, aucune dépendance externe — mais ne supporte ni sauvegarde à chaud, ni accès concurrent en écriture au-delà d'un usage modeste, ni réplication. C'est un choix délibérément temporaire, cohérent avec le périmètre de ce projet.
- **Ni SSO, ni journalisation des accès aux tableaux de bord.** Les trois comptes Metabase (§ 2.11) s'authentifient par mot de passe local, indépendant de tout annuaire du CHU ; et si Metabase consigne bien l'exécution de chaque question dans sa propre base H2, ce journal n'est ni exporté vers `ops.executions`, ni exploité par ce projet — qui a consulté quel tableau de bord, et quand, ne se répond donc pas aujourd'hui, alors que c'est précisément la question que poserait un audit d'accès à des données de santé.
- **Les réserves cliniques reposent sur des cartes de texte, qu'un utilisateur peut ignorer.** La réserve méthodologique sur la mortalité et la mention des deux seuls services équipés de monitoring (§ 2.10) sont des cartes texte posées à côté des graphiques correspondants, pas une contrainte qui empêcherait de lire le chiffre sans elles. Rien dans Metabase ne force leur lecture, ni n'interdit d'exporter le graphique seul, sans son avertissement.

3.4 Recommandations

Priorité	Recommandation
Haute	Étendre l'historique à 90 jours minimum avant d'exploiter le taux de réadmission comme une tendance. Les 28 jours disponibles en font un ordre de grandeur, pas une mesure : la réserve doit rester énoncée partout où l'indicateur est diffusé.
Haute	Faire valider les seuils d'alerte par le corps médical. Ils sont désormais configurables (<code>eds/config.py</code> , surcharge par <code>EDS_SEUIL_*</code>) et non plus codés dans le SQL ; reste à les faire arbitrer, puis à les décliner par service.
Haute	Soumettre la stratégie de pseudonymisation au DPO, en particulier la conservation du triplet (année, sexe, région) en base pilotage. La région a désormais un usage nommé — la vue d'origine géographique par service — qui fonde sa conservation au titre de la minimisation ; c'est cet usage, et lui seul, que le DPO a à valider.
Haute	Remplacer la base applicative H2 de Metabase par PostgreSQL avant toute mise en service — sauvegarde à chaud, accès concurrent, réplication : ce que H2 ne couvre pas (§ 3.3).
Moyenne	Brancher Metabase sur le SSO / annuaire du CHU plutôt que sur des comptes locaux, et mettre en place un journal des consultations de tableau de bord — qui a vu quel indicateur, et quand — exigible pour un audit d'accès à des données de santé.
Moyenne	Formaliser la gestion du sel : conservation en coffre, procédure de rotation, et conséquence assumée — sa perte rend tout rapprochement avec la source définitivement impossible.
Moyenne	Passer silver et gold en construction incrémentale si le volume dépasse quelques dizaines de millions de lignes.
Moyenne	Faire confirmer par le CHU que <code>discharge_mode</code> vide signifie toujours « séjour en cours ». C'est le cas sur ce dépôt — aucun séjour clos n'en est privé — mais la normalisation en <code>'inconnu'</code> masquerait une anomalie de saisie si la règle changeait à l'amont.
Basse	Étendre l'équipement de monitoring aux autres services, ou acter que cet indicateur restera limité à deux services.
Basse	Mettre en place une purge automatique selon les durées de conservation, actuellement non définies par le CHU.
Basse	Instaurer une revue périodique des habilitations Metabase et ClickHouse — qui appartient à quel groupe, quel compte a quel mot de passe — pour qu'un départ ou un changement de poste se traduise sans délai par un accès retiré.

Seconde livraison — L'évolution du besoin

Dépôt du 29 août 2026. Le CHU ajoute un flux d'actes techniques et deux nomenclatures, et demande cinq indicateurs supplémentaires — « sans tout refaire, sans rien casser ».

La numérotation continue celle de la première livraison : le dossier compte une trentaine de renvois internes (§ 2.5 , § 3.4 ...), et redémarrer à 1 rendrait chacun d'eux ambigu. Aucune section de la première livraison n'a été réécrite.

4. Actes, description de service et facturation

4.1 Ce que le CHU demande, et ce qui change

Le 29 août 2026, le CHU dépose de nouvelles données et formule une consigne en une phrase : « faites évoluer votre entrepôt — sans tout refaire, sans rien casser ». Trois fichiers arrivent :

Fichier	Format	Contenu
actes/2026-08-29/actes.parquet	Parquet	8 112 actes techniques — stay_id , code_ccam , acte_ts
referentiels/2026-08-29/ccam.csv	CSV	8 codes d'actes, leur libellé et leur tarif
referentiels/2026-08-29/description_service.csv	CSV	catégorie, capacité en lits et pôle — pour 7 services sur 8

Cinq indicateurs sont attendus : activité et DMS par catégorie de service, nombre d'actes par service, répartition par type d'acte, densité d'actes par lit, montant facturé (T2A). Le sujet énonce lui-même les deux pièges à éviter, et c'est autour d'eux que s'organisent les choix qui suivent.

Aucune section précédente de ce dossier n'a été réécrite. Les chiffres des § 1 à § 3, et ceux du guide d'exploitation, décrivent l'entrepôt tel qu'il était à la première livraison, et restent exacts pour ce périmètre. Deux totaux, en revanche, incluent désormais les actes : bronze passe de **79 316 à 87 443 lignes** (§ 2.9), silver de 66 369 à **74 481**, et le lake de 89 à 92 fichiers. Le tableau des sources du § 1.1 marque les référentiels « 1er jour » ; ils arrivent maintenant en **deux dépôts**, ce dont traite le § 4.2.

4.2 Un référentiel n'est pas un jour de dépôt

Le premier obstacle n'était pas dans les nouvelles données mais dans le code qui les aurait ignorées. ingerer_referentiels chargeait la nomenclature depuis **un seul jour** — le premier :

```
compteurs = charger_referentiels(self.ch, jours[0], self.run_id)
```

Ce choix était juste tant que tous les référentiels arrivaient ensemble. Il devient faux dès qu'un second dépôt en apporte d'autres : `ccam.csv` et `description_service.csv`, déposés le 29 août, n'auraient jamais été lus, et rien ne l'aurait signalé — le pipeline aurait tourné vert sur un entrepôt amputé.

La correction ne consiste pas à prendre le dernier jour plutôt que le premier, ce qui aurait fait disparaître `services.csv` et `cim10.csv` à la place. **Un référentiel est un FICHIER, pas un jour.** Chacun est désormais résolu indépendamment, sur le dépôt le plus récent qui le fournit (`_dernier_depot` , dans `eds/warehouse.py`) :

```
bronze.ref_services      <- referentiels/2026-08-01/services.csv
bronze.ref_cim10         <- referentiels/2026-08-01/cim10.csv
bronze.ref_ccam          <- referentiels/2026-08-29/ccam.csv
bronze.ref_description_service <- referentiels/2026-08-29/description_service.csv
```

Cette formulation règle aussi un cas que l'ancienne ne couvrait pas : un référentiel **redéposé** remplace maintenant sa version précédente, au lieu d'être ignoré au profit du premier dépôt. Et un référentiel qu'aucun dépôt ne fournit est **signalé, sa table laissée intacte** — la tronquer remplacerait une nomenclature utilisable par une table vide, sans rien apporter.

Le journal a gagné deux champs (`table` , `fichier`) à cette occasion : quatre chargements de référentiels produisaient jusque-là quatre lignes indiscernables.

4.3 « Sans retraiter l'existant » — la propriété était déjà là

Le sujet demande d'ingérer le nouveau dépôt **par le pipeline incrémental**. Aucun développement n'a été nécessaire : la propriété existait, il suffisait de la vérifier. Une fois `actes` déclarée comme source connue, un `python -m eds.run` sans option ne traite que le jour manquant :

```
copie lake      (jour=2026-08-29)
bronze chargé   (jour=2026-08-29, lignes=8112, source=actes)
référentiel chargé (jour=2026-08-01, table=bronze.ref_services)
référentiel chargé (jour=2026-08-29, table=bronze.ref_ccam)
```

Les 28 jours antérieurs ne sont ni relus ni recopiés. Silver et gold, eux, sont intégralement recalculés — c'est le choix documenté au § 2.7 (« incrémental en amont, recalcul en aval »), et il prend tout son sens ici : une couche dérivée qui se reconstruit n'a pas de migration à subir quand son schéma change.

4.4 Le premier piège : un référentiel incomplet

« Le référentiel de description peut être incomplet : que faites-vous d'un service non décrit ? »

Le service **NEURO n'est pas décrit** — 7 services sur 8 le sont. Ce n'est pas un détail : la Neurologie porte **1 208 séjours et 1 471 actes**, soit 18 % de l'activité technique de l'hôpital.

Trois réponses étaient possibles, deux sont mauvaises :

- **L'exclure** (un `INNER JOIN` sur le référentiel de description). C'est ce qui se produit par défaut quand on ne se pose pas la question. 18 % de l'activité disparaît de tout indicateur, et **le total par catégorie ne vaut plus le total de l'hôpital** — un écart de 1 208 séjours que rien ne signale. C'est le mode de défaillance le plus dangereux : silencieux.
- **Lui inventer des valeurs**. Une capacité moyenne, une catégorie « médecine » par analogie. Le chiffre devient faux sans cesser d'être plausible, ce qui est pire qu'une absence.
- **Le conserver, en distinguant selon le RÔLE de la colonne**. C'est le choix retenu.

Catégorie et pôle sont des axes de regroupement. Ils valent `'non renseigné'`. La Neurologie reste comptée, la somme par catégorie fait toujours 6 729 séjours, et la lacune du référentiel **se lit dans le résultat** au lieu de s'y cacher :

Catégorie	Séjours	DMS (jours)
medecine	2 652	5,71
urgences	1 423	2,15
non renseigné	1 208	7,06
pediatrie	503	3,19
chirurgie	476	4,39
reanimation	467	9,05

La capacité en lits est un dénominateur. Elle reste `NULL`, et `kpi_densite_actes_lit` **n'a pas de ligne** pour ce service. Un ratio indéfini est absent, jamais nul : publier `0` ferait passer la Neurologie pour un service sans plateau technique, ce qui est l'inverse de la vérité.

Cette absence n'est pas une perte silencieuse, parce qu'elle est **chiffrable par différence** : `kpi_actes_service` totalise 8 112 actes, `kpi_densite_actes_lit` en couvre 6 641, et l'écart de **1 471** est exactement l'activité du service non décrit. `tests.verifier` en fait un contrôle, et le tableau de bord l'explique à côté du graphe plutôt que de laisser le lecteur découvrir un service manquant.

Le résultat net : **la Neurologie figure dans quatre des cinq indicateurs**, et n'est absente que de celui dont le dénominateur lui manque.

4.5 Le second piège : le service vient du séjour

« "Actes par service" : le service est porté par le séjour, pas par l'acte — récupérez-le sans relier deux tables de faits entre elles. »

Joindre `fact_acte` à `fact_sejour` ligne à ligne serait un **fan trap** : un séjour portant trois actes verrait sa durée, son mode d'admission et son indicateur de réadmission comptés trois fois. Le § 2.5 documentait déjà ce risque pour justifier trois faits distincts plutôt qu'un seul ; il se représente ici sous une autre forme.

La parade suit le chemin déjà emprunté par `silver.diagnostics` et `silver.monitoring` : **le service est recopié dès silver**, depuis le séjour porteur lu dans `bronze.sejours`. `fact_acte` le lit tel quel, et aucune jointure entre faits n'existe nulle part dans la construction.

Les indicateurs qui croisent réellement les deux mondes — « nombre moyen d'actes par séjour » — agrègent **chaque fait séparément**, puis joignent les deux résultats sur `service_code`, une clé de **dimension** :

```

FROM gold_pilotage.dim_service AS d
LEFT JOIN (SELECT service_code, count() AS nb_actes
           FROM gold_pilotage.fact_acte GROUP BY service_code) AS a ...
LEFT JOIN (SELECT service_code, count() AS nb_sejours
           FROM gold_pilotage.fact_sejour GROUP BY service_code) AS sj ...


```

Une jointure entre deux agrégats à la même maille ne multiplie aucune ligne. C'est la jointure **ligne à ligne** qui est interdite, pas la comparaison — et `tests.verifier` le prouve plutôt que de l'affirmer : la somme des `nb_sejours` de `kpi_actes_service` vaut **6 729**, le total réel des séjours. Si le service avait été récupéré par un croisement fait-à-fait, ce nombre serait gonflé du nombre d'actes par séjour, et le contrôle échouerait.

L'indicateur lui-même est exposé en **deux lectures**, parce que « actes par séjour » est ambigu : rapporté à *tous* les séjours du service (1,21 en moyenne) ou aux seuls séjours ayant reçu un acte (1,59). Un service où un séjour sur dix reçoit dix actes et un service où chaque séjour en reçoit un donnent la même première mesure et deux secondes très différentes.

4.6 Ce que l'étoile devient

Le modèle gagne un quatrième fait et une dimension, et en enrichit une autre.



fact_acte ne porte pas **patient_pseudo**, contrairement aux trois autres faits. Ce n'est pas un oubli. Les trois autres le portent parce qu'un usage nommé l'exige : cohortes de patients par pathologie, réadmission, origine géographique. **Aucun des cinq indicateurs demandés ne dénombre de patients** — ils comptent des actes, des séjours, des lits et des euros. Ajouter un pseudonyme « au cas où » contredirait exactement la minimisation défendue au § 3.4, où `region_code` n'a été conservé que parce qu'une vue d'activité lui donnait un usage. Le séjour reste joignable par `stay_id` si le besoin apparaît : ce sera alors une décision, pas un droit déjà distribué.

Le compte de pilotage, lui, n'obtient même pas `stay_id` sur ce fait — il relierait deux actes entre eux, et le pilotage analyse des volumes.

Le **tarif vit dans `dim_ccam`, jamais sur le fait**. C'est une donnée de facturation : elle change dans le temps sans que les actes déjà réalisés changent. Figée sur chaque ligne de fait, une révision tarifaire obligerait à réécrire l'historique.

4.7 Les cinq indicateurs

#	Table	Ce qu'elle porte	Résultat
①	kpi_activite_categorie	séjours et DMS par catégorie	6 catégories, 6 729 séjours au total
②	kpi_actes_service	actes et intensité par service	8 services, 8 112 actes, 1,21 par séjour
③	kpi_actes_type	répartition par code CCAM	8 codes, parts sommant à 100 %
④	kpi_densite_actes_lit	actes rapportés aux lits	7 lignes — URGENCES 86,55 actes/lit
⑤	kpi_facturation_service	montant T2A par service	8 services, 2 199 450 €

Activité technique et facturation

🔍 📄 ⌚ 📌 ⓘ ⋮

Activité technique et facturation

Ce tableau de bord répond aux cinq indicateurs du sujet d'ÉVOLUTION — activité et DMS par catégorie de service, actes par service, actes par type, densité d'actes par lit, montant facturé (T2A). Il s'ajoute au tableau de bord « Pilotage hospitalier », qu'il ne remplace pas : les indicateurs de la première livraison y restent inchangés.

Nombre d'actes techniques

8,112

Montant facturé (T2A)

2,199,450


Actes par séjour

1.21


Services décrits par le référentiel

7 / 8

Activité et DMS par catégorie de service



Nombre d'actes par service




Répartition des actes par type

acte	nb_actes	part_pct	nb_sejours_concernes	tarif_euros
Radiographie du thorax	1,043	12.86	978	25
Consultation de suivi	1,039	12.81	983	25
Coronarographie	1,030	12.7	969	450
Pose de catheter central	1,025	12.64	972	120
Coloscopie totale	1,015	12.51	949	260
Ventilation mecanique assistee	1,000	12.33	946	220
IRM cerebrale	982	12.11	925	300

8 rows

Densité d'actes par lit



Pourquoi la Neurologie manque ici


Le référentiel de description fourni par le CHU couvre 7 des 8 services : la Neurologie n'y figure pas, alors qu'elle réalise 1 471 actes, soit 18 % de l'activité technique.

Deux réponses différentes, parce que les colonnes n'ont pas le même rôle :

- **Catégorie et pôle** sont des axes de regroupement. Ils valent « non renseigné », et la Neurologie reste comptée partout — le total par catégorie fait toujours 6 729 séjours, celui de l'hôpital entier.
- **La capacité en lits est un dénominateur**. Elle est inconnue : ce graphe n'a donc pas de ligne pour la Neurologie. Afficher zéro la ferait passer pour un service sans plateau technique, ce qui serait faux.

L'écart se lit : 8 112 actes au total, 6 641 couverts ici. La différence, 1 471, est exactement l'activité du service non décrit — et non une perte.

Montant facturé par service (T2A)



Le troisième tableau de bord, ajouté sans toucher aux deux premiers. Il rend visible d'un coup d'œil ce que le § 4.4 explique : la Neurologie figure dans « Nombre d'actes par service », dans « Activité et DMS par catégorie » — sous l'étiquette « non renseigné » — et dans « Montant facturé », mais pas

dans « Densité d'actes par lit », faute de dénominateur. L'encadré placé à côté de ce graphe donne au lecteur du tableau de bord la même explication que ce rapport, sans qu'il ait à l'ouvrir.

Deux propriétés valent d'être signalées.

Les tarifs manquants sont comptés, pas absorbés. Un acte dont le code est absent de la nomenclature n'a pas de tarif : il est exclu du montant et compté dans `nb_actes_sans_tarif`. Sans cette colonne, un total sous-évalué serait indiscernable d'une activité plus faible. Sur ce dépôt, tous les codes se résolvent — la colonne vaut 0 partout, et c'est démontré par injection plutôt que constaté.

Chaque table est confrontée à son recalcul depuis les faits. Une table d'indicateur est une copie dérivée : elle peut diverger. Les cinq nouvelles rejoignent donc le harnais du § 2.10, et dix-sept contrôles supplémentaires vérifient ce qui leur est propre — conservation des totaux, absence de ligne pour un dénominateur inconnu, écart chiffré avec les services non décrits.

4.8 La qualité des actes, démontrée sur des règles qui ne servent pas

`silver.actes` applique aux actes les règles déjà en vigueur pour les diagnostics et les relevés, avec trois motifs de quarantaine : `sejour_inconnu`, `sejour_ecarte`, `acte_hors_sejour`. Le contrôle physiologique n'a pas d'objet ici ; l'ordre et l'exclusivité mutuelle des trois autres sont ceux du § 2.8.

Aucun n'attrape la moindre ligne sur ce dépôt : 8 112 actes, aucun séjour orphelin, aucun code hors nomenclature, aucun acte hors de la fenêtre de son séjour. Une règle qu'aucune donnée n'exerce n'étant pas une preuve, six actes fautifs sont injectés dans `tests.demontrer_qualite` — deux hors fenêtre, un orphelin, un sans patient identifié, un sur un séjour temporellement incohérent, un à code inconnu — puis l'entrepôt est remis en état.

Les 82 actes portés par les 68 séjours à incohérence temporelle sont **conservés**, avec `sejour_coherent = 0` : la décision de l'intervenant rapportée au § 2.8 vaut pour les actes comme pour les relevés. Un acte réalisé reste un acte réalisé, quelle que soit la qualité de saisie des deux dates qui encadrent le séjour.

4.9 Deux défauts trouvés en chemin

Un repli mort depuis l'origine. `coalesce(c.libelle, 'inconnu')` après un `LEFT JOIN` ne se déclenche jamais : avec `join_use_nulls = 0` — le défaut de ClickHouse — une absence de correspondance remplit une colonne `String` avec la **chaîne vide**, pas avec `NULL`. Le code documentait déjà ce piège et s'en prémunissait pour le drapeau `sejour_coherent` (`sj.stay_id != ''`, jamais `IS NOT NULL`), mais les deux enrichissements par libellé y échappaient : un service absent de `ref_services` ou un code CIM-10 absent de `ref_cim10` aurait produit un libellé **vide**, jamais « inconnu ». Corrigé aux trois endroits en testant la clé de jointure. Aucun changement de comportement sur ce dépôt — tous les codes s'y résolvent — mais le défaut ne se serait manifesté que le jour d'un référentiel incomplet, c'est-à-dire précisément le cas que cette évolution introduit. C'est la démonstration à code inconnu qui l'a révélé.

Une partition indestructible. Les actes de démonstration étaient d'abord injectés au 28 août, comme ceux du monitoring. Or la remise en état ne recharge que les partitions **dont la source existe**, et `actes` n'a de dépôt qu'au 29 : ces lignes survivaient à la démonstration, invisibles au contrôle « aucune ligne de démonstration ne subsiste » qui ne les cherchait pas encore. Le jour de dépôt des injections est désormais celui de la source réelle, l'horodatage de l'acte restant au 28 — un acte antérieur à son dépôt est ici le cas normal.

4.10 Ce qu'il a fallu accepter

Faire évoluer une table gold demande de la supprimer une fois. `30_gold.sql` n'exécute que des `CREATE TABLE IF NOT EXISTS`, qui n'ajoutent pas les colonnes nouvelles à une table déjà présente : `dim_service` a dû être supprimée pour être reconstruite avec `categorie`, `capacite_lits` et `pole`. C'est sans perte — `gold` est intégralement dérivé de `silver`, et se reconstruit en une exécution — mais c'est une manipulation manuelle, à faire une fois, que le pipeline ne prend pas en charge. Une évolution ultérieure du schéma `gold` demandera le même geste. L'alternative, un `ALTER TABLE ... ADD COLUMN IF NOT EXISTS` par colonne, ajouterait une migration versionnée à maintenir pour une couche qui n'a précisément aucune migration à subir : le geste manuel a été préféré, mais il doit être connu.

Le pipeline émet davantage d'avertissements. `charger_bronze_jour` journalise `source absente` pour chaque jour sans dépôt d'une source donnée. `actes` n'étant déposée qu'une fois, elle en produit 28 à chaque exécution complète, portant le total de 29 à 57. Le motif préexistait — `patients` en produisait déjà 26 — mais le volume double, et un `WARNING` qui décrit une situation parfaitement normale use le signal. Les faire passer en `INFO` change le comportement de journalisation décrit au guide d'exploitation, § 3 : le point est signalé plutôt que tranché unilatéralement.

Un garde-fou reste à poser. `copier_jour` recopie à l'octet toute source sans transformation déclarée. La liste blanche de `_ligne_patient` protège explicitement `patients` contre une colonne identifiante que le CHU ajouterait demain ; `actes` n'a pas cet équivalent. Le fichier ne porte aujourd'hui que `stay_id`, `code_ccam` et `acte_ts` — vérifié — mais un `patient_id` ajouté à la source traverserait le lake en clair. Le contrôle manque, et son absence est une dette assumée, pas un oubli.

4.11 Ce que cette évolution apprend

Le sujet dit « sans tout refaire, sans rien casser ». Les deux moitiés n'ont pas coûté la même chose.

Ne rien casser n'a rien coûté, et c'est le résultat le plus net. Aucun indicateur de la première livraison n'a bougé — la DMS en réanimation vaut toujours 9,05 jours, le case-mix et la prévalence sont inchangés, `tests.verifier_conformite` reste au vert face aux valeurs de référence de l'intervenant. Non parce que la modification était petite, mais parce que l'entrepôt était déjà instrumenté : les contrôles existaient avant d'être nécessaires, et c'est eux qui ont permis de modifier sans crainte plutôt que de vérifier après coup.

Ne pas tout refaire, en revanche, s'est décidé. La tentation était réelle de traiter la Partie II comme un projet séparé — un second entrepôt, un second code. C'est précisément ce qui aurait rendu la non-régression indémontrable : deux codes différents donnant deux résultats ne prouvent rien. Un seul entrepôt, augmenté, est ce qui permet d'affirmer que les anciens chiffres sont les mêmes — et de le prouver.

Enfin, les deux défauts du § 4.9 n'ont pas été trouvés par relecture. Ils sont sortis d'une démonstration écrite pour prouver une règle qui ne servait à rien : le repli mort ne s'est manifesté que sur un code CCAM inventé pour l'occasion. Une règle qui ne s'exerce sur aucune donnée réelle n'est pas du zèle — c'est le seul endroit où un défaut latent devient visible avant qu'un dépôt futur ne le rende coûteux.